

Activitat 1: Preprocés de les dades

Enunciat

Anàlisi Estadística - Semestre 2025.1

Índice

1 Estructura de les dades	3
1.1 Diccionari de dades	3
1.2 Fitxer de dades	3
2 Tipus de dades i possibles inconsistències	3
2.1 Variables quantitatives	4
2.2 Variables qualitatives	4
2.2.1 Països i codis de països	4
2.2.2 Continent	4
2.2.3 Règim	4
2.2.4 Regió	4
2.2.5 Income	4
3 Valors extrems	4
3.1 Desigualtat (GINI)	4
3.2 Emissions de gasos d'efecte hivernacle	4
4 Correlacions	5
4.1 Matriu de correlacions en indicadors de pobresa	5
4.2 Correlacions amb esperança de vida	5
5 Imputació	5
6 Taula resum	5

Introducció

En aquesta activitat realitzarem l'anàlisi exploratòria i el preprocessament del conjunt de dades Global Sustainability (<https://www.kaggle.com/datasets/trucue/worldsustainabilitydataset/data>), el qual agrupa informació sobre el rendiment de 173 països en relació amb diversos indicadors de sostenibilitat al llarg d'un període de 19 anys. El conjunt de dades s'ha generat a partir de la fusió de múltiples fonts internacionals, entre elles el World Bank DataBank. Inclou un total de 54 variables, que abasten diferents dimensions de la sostenibilitat:

- Econòmica: Es proporcionen indicadors com el percentatge d'exportacions del país, producte nacional brut, creixement de la renda nacional bruta ajustada per càpita, estalvi net ajustat, etc.
- Social: Conté indicadors com l'esperança de vida en néixer, índex de Gini (desigualtat d'ingressos), educació, etc.
- Ambiental: Indicadors que tenen en compte la degradació de recursos naturals i els danys ambientals.

Aquest conjunt de dades ens ofereix múltiples possibilitats per explorar els indicadors vinculats als objectius de desenvolupament sostenible (ODS) de les Nacions Unides. En l'activitat, explorarem aquests indicadors i preprocessarem el conjunt de dades per a la seva anàlisi posterior.

A causa de l'extensió del conjunt de dades, ens centrarem només en algunes de les variables del conjunt.

Criteris de verificació i de normalització de les variables:

A continuació es mostren els criteris amb què s'han de netejar les dades del conjunt:

- Revisen la naturalesa de les variables (text, categòrica, numèrica). En cas que el tipus de variable que ha assignat R no coincideixi amb el tipus que li correspondria, s'haurà de corregir.
- Els noms de les columnes s'han de canviar segons el fitxer "Data Dictionary.xlsx" proporcionat.
- En les variables de tipus numèric, el separador decimal és el punt.
- Els valors perduts han de tenir el valor NA.
- Les variables numèriques amb valors NA s'han d'imputar segons les indicacions que es donen més avall.
- Per mantenir la consistència amb el diccionari de dades, es mantindran els noms de les variables en el fitxer de dades. Es pot mostrar la informació amb noms més comprensibles a les taules i gràfics si és necessari.

A tenir en compte per realitzar l'activitat:

- Es valora la precisió dels termes utilitzats (és necessari utilitzar de forma precisa la terminologia de l'estadística).
- També es valora la concisió de la resposta. No es tracta de fer explicacions massa llargues o documents molt extensos. Cal explicar el resultat i argumentar la resposta a partir dels resultats obtinguts de manera clara i concisa.
- Mostreu en el document només allò imprescindible i que dona resposta a la pregunta plantejada. No és necessari mostrar tot el procés d'exploració que s'ha realitzat.
- No es poden fer llistats complets del conjunt de dades a la solució. Això generaria un document amb centenars de pàgines i dificultaria la revisió del text. Per comprovar les funcionalitats del codi sobre les dades, es poden utilitzar les funcions head i tail que només mostren unes línies del fitxer de dades.

- Com a objectiu secundari, aquesta activitat pretén desenvolupar el coneixement del llenguatge R, aprofitant al màxim les seves característiques. En aquest sentit, sempre que sigui possible, feu servir codi optimitzat i elegant. Per exemple, per aplicar un mateix codi a diferents variables, feu servir les funcions de la família `apply` o funcionalitats de `dplyr`. Eviteu la inspecció visual (manual) sempre que sigui possible. Per mostrar les taules, es pot utilitzar la llibreria `kableExtra`.
- Per dubtes tècnics sobre R i el seu entorn de programació, us recomanem usar l'aula de Laboratori R que està a la vostra disposició.

Requisits per al lliurament:

- Cal lliurar l'arxiu `Rmd` i l'arxiu de sortida (PDF o html). L'arxiu de sortida ha d'incloure: el codi i el resultat de l'execució del codi (pas a pas).
- Per facilitar la correcció, els arxius s'han de lliurar per separat a l'aula. És a dir, en lloc d'un únic arxiu comprimit, lliureu cada arxiu per separat.
- Cal respectar la mateixa numeració dels apartats que l'enunciat.

1 Estructura de les dades

1.1 Diccionari de dades

Carregueu les dades del conjunt `WorldSustainabilityDataset` i del diccionari de dades (Data Dictionary).

A continuació examineu la informació que està emmagatzemada al diccionari, on es detallen les variables, el seu codi, una breu descripció, a quin ODS (SDG en anglès) pertanyen i la font de dades d'on procedeixen.

Per resumir aquesta informació i fer més comprensible la gestió de les dades al llarg de l'activitat, crearem dues taules informatives. A la primera, s'han de mostrar les variables i, si escau, l'ODS associat. Les columnes d'aquesta taula han de ser: número de l'ODS (si s'escau), codi de la variable (indicador) i breu descripció de la variable. Podeu utilitzar la mateixa descripció que conté el fitxer diccionari. No cal traduir ni redactar de nou.

A la segona taula, mostreu el número de l'ODS i la seva descripció. En ambdues taules, ordeneu el llistat segons el número de l'ODS.

1.2 Fitxer de dades

A continuació, prepararem el fitxer de dades per a la seva posterior manipulació. Per això, canvieu el nom de les columnes segons els codis establerts en el diccionari de dades. Seguiu la mateixa nomenclatura que en el diccionari de dades. Per exemple, la variable esperança de vida té el codi `SP.DYN.LE00.IN`. En la mesura del possible, realitzeu aquest procés de forma automàtica o semi-automàtica.

Reanomenau les columnes pertinents amb els noms següents: `Country`, `CountryCode`, `Regime`, `Income`, `Region`.

En finalitzar el procés, mostreu el llistat amb els noms de les columnes.

2 Tipus de dades i possibles inconsistències

Reviseu els tipus de les dades i el format de les mateixes. En cas d'inconsistències en el format, corregiu-les. Seguiu les instruccions que es detallen a continuació.

2.1 Variables quantitatives

Reviseu els valors de les variables quantitatives i apliqueu les transformacions de format necessàries. Si hi ha valors buits, s'han de substituir per NA. Si es troben valors extrems, erronis o NAs en alguna variable quantitativa, els tractarem en apartats posteriors.

2.2 Variables qualitatives

Reviseu els valors de les variables qualitatives i apliqueu les transformacions de format necessàries. Si hi ha valors buits, s'han de substituir pels valors correctes o, si no es coneixen, per NA. Per a una millor estructuració d'aquest apartat, tracteu cada variable en una subsecció diferent.

2.2.1 Països i codis de països

2.2.2 Continent

2.2.3 Règim

2.2.4 Regió

2.2.5 Income

3 Valors extrems

Examinem els valors extrems d'algunes variables d'interès. En concret, l'índex GINI i les emissions de gasos d'efecte hivernacle. Per fer el codi més comprensible podeu utilitzar els noms GINI i GHE respectivament en els gràfics i taules.

3.1 Desigualtat (GINI)

Visualitzeu la distribució de l'índex GINI entre els diferents països al llarg dels anys. Interpreteu el gràfic. Observeu si existeixen valors erronis o extrems que s'hagin de processar. Si ho considereu oportú, apliqueu una transformació sobre els valors extrems. Podeu escollir la transformació de dades que considereu més adequada.

3.2 Emissions de gasos d'efecte hivernacle

Reviseu els valors extrems en la variable GreenHouse Gas Emissions (emissions de gasos d'efecte hivernacle). De manera anàloga al cas anterior, visualitzeu un gràfic que mostri la distribució d'emissions de gas al llarg dels anys. Interpreteu el gràfic i reflexioneu sobre la necessitat d'aplicar transformacions. Si escau, realitzeu les transformacions oportunes.

A continuació, farem servir la detecció de valors extrems per visualitzar una llista dels països més contaminants. Escolliu l'any 2018 i mostreu la llista de països amb emissions de gasos extremadament grans. Visualitzeu aquesta llista incloent-hi el nom del país i el valor de la variable de major a menor emissió.

4 Correlacions

4.1 Matriu de correlacions en indicadors de pobresa

Calculeu les correlacions entre les variables corresponents als ODS 1,2,3,4 (només SE.PRM.UNER.ZS), 10 i GDP (producte interior brut). Mostreu una matriu amb el resultat i interpreteu.

Nota: per visualitzar la matriu, podeu canviar el nom de les variables per facilitar la comprensió del lector.

4.2 Correlacions amb esperança de vida

Examineu específicament les variables que presenten més correlació amb l'esperança de vida. Mostreu una taula amb les variables ordenades de més a menys correlació. Interpreteu.

5 Imputació

A mode il·lustratiu, realitzarem la imputació de NAs per a la variable esperança de vida. Reviseu en quins anys aquesta variable presenta valors perduts.

Com veureu, l'any 2000 no té dades. En aquest cas, realitzarem la imputació amb les dades de l'any 2001. Per a la resta d'anys, imputeu el valor de la variable a partir de la mitjana dels veïns més propers, fent servir les cinc variables més correlacionades amb esperança de vida.

Nota: Podeu fer servir la funció kNN de la llibreria VIM.

6 Taula resum

Calcular les mesures de tendència central i dispersió (robustes i no robustes) de les variables quantitatives següents: pobresa (SI_POV_DAY1), GINI i esperança de vida. Es presentaran dues taules, una amb les mesures de tendència central i una altra amb les mesures de dispersió. En les mesures de tendència central, mostreu la mitjana i la mediana. Pel que fa a les mesures de dispersió, mostreu la desviació estàndard i la desviació absoluta respecte de la mediana.

A causa de la gran variabilitat entre les dades, agrupeu les dades per regions i mostreu només les dades de l'últim any disponible. A les taules, podeu utilitzar noms per a les variables que siguin més comprensibles.

Nota: Realitzeu aquest càlcul de manera automatitzada, fent servir funcionalitats de la família *apply* o *dplyr*.

Puntuació de l'activitat

- Apartat 1 (10%)
- Apartat 2 (20%)
- Apartat 3 (20%)
- Apartat 4 (20%)
- Apartat 5 (10%)
- Apartat 6 (10%)
- Qualitat de l'informe dinàmic (10%)